

Deep Research : mémoire, validité et failure mining
Emulation d'amplificateurs : recherche et audit de validite
5 septembre 2026 – Note exploratoire

Sommaire

1	Résultat exécutif	2
2	Question, méthode et limites	2
3	Synthèse des preuves	2
3.1	Aucun vainqueur architectural universel	2
3.2	État transporté et gradient appris sont deux questions différentes	2
3.3	La métrique moyenne cache les limites génératives	3
4	Failure mining préenregistrable	3
5	Idées de recherche classées	3
5.1	I01 - Mesurer l'horizon de mémoire utile	3
5.2	I02 - Observer compact à cadence lente	3
5.3	I03 - Encodeur d'état initial dry-only	4
6	Décision pour la campagne	4
7	Artefacts associés	4

1 Résultat exécutif

La meilleure prochaine expérience n'est pas « un observer plus gros ». Elle doit d'abord rendre la comparaison symétrique, puis mesurer où une mémoire lente aide réellement. L'audit du code a trouvé deux facteurs capables de fausser la sélection : le teacher conservait son état à travers des chunks de 48 000 échantillons, tandis que les comparateurs étaient remis implicitement à zéro tous les 12 000; sa validation était pondérée par échantillons, celle des comparateurs par nombre de segments. Des coordonnées de sortie identiques ne corrigent pas cette différence d'historique.

La recommandation est donc un benchmark prospectif à contexte commun : reset de toutes les familles chaque seconde, préroll identique de 14 400 échantillons, scoring du suffixe seulement et agrégation pondérée par échantillons. Cette restriction réduit la portée de la revendication : un résultat positif signifie « meilleur comparateur ouvert réentraîné localement sous le contexte commun gelé », pas reproduction exacte de toutes les recettes publiées ni supériorité perceptive universelle.

Parmi les quinze pistes générées dans la revue exploratoire, trois sont prioritaires après un verdict v9 valide : mesurer l'horizon de mémoire utile, remplacer l'observer lourd par un observer compact à cadence lente, puis tester un encodeur d'état initial dry-only. Elles sont falsifiables et peuvent être évaluées sur les splits train/validation sans ouvrir les tests.

2 Question, méthode et limites

Question : quelles limites de représentation, d'apprentissage et de mesure empêchent une émulation dry/wet causale de reproduire un dispositif analogique, et quelles expériences bornées séparent ces mécanismes ?

La recherche couvre 2016-2026 et conserve 33 sources primaires ou notices institutionnelles. Les recherches ont ciblé arXiv, DAFx, PMLR, DBLP, ISMIR, Frontiers et les dépôts universitaires. Le journal complet des requêtes et des exclusions est dans `sources/search_log.md`; le corpus déduplicé est dans `sources/corpus.json`. Le CLI académique prévu n'était pas disponible, donc une recherche web ciblée a servi de repli. Cette méthode est une revue exploratoire, pas une revue systématique PRISMA : il n'y a ni export exhaustif des résultats bruts, ni double screening, ni méta-analyse.

Les quatre DOI déclarés ont été testés. Trois ont fourni leurs métadonnées Crossref; le DOI KLANN résout mais ses métadonnées ont été corroborées par la notice Aalto. Aucun DOI absent n'a été inventé. Le registre `sources/claim_ledger.md` relie chaque conclusion opérationnelle à ses sources et indique si la preuve est directe, transférée ou issue de l'audit local.

3 Synthèse des preuves

3.1 Aucun vainqueur architectural universel

La comparaison multi-effets de Comunità et collaborateurs montre l'intérêt des modèles state-space et du conditionnement temporel dans son propre cadre, alors que l'étude comparative de Simionato et Fasciani rapporte des avantages qui dépendent de la classe d'effet. Ces résultats n'ont ni les mêmes données, ni les mêmes budgets, ni exactement les mêmes recettes. Ils soutiennent une sélection par dispositif et protocole gelé, pas un classement universel. ([Comunità et al., 2025](#), [Simionato et Fasciani, 2024](#))

Les RNN modestes restent des baselines fortes pour l'amplification, comme le montrent les travaux de Wright, mais ces résultats ne garantissent pas la capture de toutes les dynamiques lentes. Les résultats historiques sur références SPICE ne sont pas interchangeables avec des captures de matériel réel. ([Wright et al., 2019](#), [Wright et Välimäki, 2020](#), [Damskägg et al., 2018](#))

3.2 État transporté et gradient appris sont deux questions différentes

Avec une TBPTT de 12 000 échantillons à 48 kHz, le gradient direct couvre 0,25 s. Un modèle peut transporter un état au-delà, mais cela ne prouve pas que cet état a reçu un signal d'apprentissage adéquat. Les travaux sur la TBPTT non biaisée et adaptative établissent le mécanisme général; leur transfert à l'émulation audio reste une hypothèse à tester. ([Tallec et Ollivier, 2017](#), [Aicher et al., 2020](#))

S4, S4D, LRU et Mamba fournissent différentes paramétrisations de mémoire longue, mais aucune ne détermine à elle seule l’horizon utile d’une pédale ou d’un ampli. Les difficultés rapportées sur les compresseurs optiques rendent plausible une analyse conditionnée par les régimes attaque/release. (Gu et al., 2021, Gu et al., 2022, Orvieto et al., 2023, Simionato et Fasciani, 2024)

3.3 La métrique moyenne cache les limites génératives

ESR et MAE résument l’erreur mais ne localisent pas sa cause. Une campagne de failure mining descriptive doit conserver les fenêtres dans les coordonnées source et les relier à des facteurs calculés uniquement sur le dry : niveau, crest factor, centroïde spectral et transientness. Le résidu wet peut ensuite servir de variable réponse, sans sélectionner une nouvelle architecture sur ces résultats. Les pertes perceptuelles et multi-résolution publiées justifient une lecture multi-métrique, pas le remplacement post hoc de la métrique primaire. (Wright et al., 2020, Cassidy et al., 2023)

Une seconde limite possible est l’aliasing. Les travaux récents proposent le lissage d’activations et l’antidérivée pour certains modèles neuronaux. Cela justifie un diagnostic spectral conditionnel, mais pas l’ajout d’un nouveau traitement à la campagne v9 : ce serait une variante scientifique distincte. (Sato et al., 2025, Mikkonen et al., 2025)

4 Failure mining préenregistrable

L’unité descriptive proposée est une fenêtre source fixe sur validation, jamais un extrait choisi après inspection des tests. Pour chaque fenêtre : calculer ESR local, MAE, erreur MR-STFT et erreur d’enveloppe; calculer sur le dry niveau RMS, crest factor, centroïde spectral et transientness. Produire des quantiles et des courbes de calibration par dispositif. Les comparaisons candidat-comparateur doivent être appariées sur la même fenêtre.

Quatre signatures départagent des mécanismes :

1. Erreur croissante avec l’horizon depuis un reset, mais pas avec le niveau : mémoire ou initialisation d’état.
2. Erreur concentrée sur fortes transitoires et hautes fréquences : branche rapide, resampling ou aliasing.
3. Erreur dépendante du niveau avec gain_error négatif : saturation ou calibration d’amplitude insuffisante.
4. Erreur de release après transitoire : dynamique lente mal apprise malgré un score moyen acceptable.

Ce mining reste descriptif et inéligible à la sélection v9. Une hypothèse nouvelle issue de ces graphiques exige une lignée prospective séparée.

5 Idées de recherche classées

5.1 I01 - Mesurer l’horizon de mémoire utile

Injecter, sur train/validation, des resets contrôlés à plusieurs distances avant la zone scorée (0,25; 0,5; 1; 2; 4 s) et tracer la récupération de l’erreur par dispositif. Prédiction : si la voie lente apporte réellement une information utile, son avantage augmente avec l’historique disponible puis atteint un plateau. Falsification : courbe plate ou avantage limité aux premières dizaines de millisecondes. Coût : évaluation seulement sur checkpoints gelés.

5.2 I02 - Observer compact à cadence lente

Remplacer l’observer S4 64×64 par une petite récurrence ou un filtre d’état opéré à cadence décimée, puis interpoler ses paramètres FiLM. L’analogie vient des modèles hybrides et filtres différentiables : réserver la capacité à la dynamique lente et laisser la WaveNet modéliser la non-linéarité rapide. (Kuznetsov et al., 2020, Yu et al., 2024, Engel et al., 2020)

5.3 I03 - Encodeur d'état initial dry-only

Apprendre un encodeur causal sur un préfixe dry pour initialiser l'état du modèle avant la fenêtre scorée. Les deep encoder networks fournissent une motivation en identification non linéaire, mais l'efficacité sur amplificateurs doit être démontrée. Prédiction : réduction de l'erreur juste après reset sans dégrader le régime stationnaire. Falsification : aucune réduction appariée, ou dépendance à des cibles wet indisponibles à l'inférence. (Beintema et al., 2021)

6 Décision pour la campagne

Avant tout nouveau run : qualifier le contrat de contexte commun sur entrées synthétiques, vérifier gradients finis et mémoire sur les trois comparateurs, puis geler le snapshot. Ensuite seulement, exécuter la matrice de développement et le failure mining validation. La confirmation Rodent/Fuzzy Logic et ses tests restent scellés jusqu'aux locks candidat, comparateur, recettes et checkpoints.

Cette recommandation ne promet pas un GO. Elle vise un verdict interprétable, y compris si le résultat final est NO-GO-OBJECTIVE-SOTA.

7 Artefacts associés

- Revue détaillée et bibliographie : review.md, review.bib.
- Corpus déduplicué : sources/corpus.json, sources/corpus.md.
- Journal de recherche : sources/search_log.md.
- Registre des conclusions : sources/claim_ledger.md.
- PDF de la revue détaillée : output/pdf/review.pdf.