

Au-dela du score moyen
Emulation d'amplificateurs : revue et pistes de recherche
5 septembre 2026 – Note exploratoire

Sommaire

1	Résumé	2
2	Périmètre et méthode	2
3	Ce que la littérature permet de conclure	3
3.1	Architecture et dispositif doivent être distingués	3
3.2	La mémoire conservée et le gradient appris ne sont pas la même chose	3
3.3	Des dynamiques compactes méritent un vrai contrôle	3
3.4	Les scores et les oreilles répondent à des questions différentes	3
3.5	Antialiasing et coût sont des axes séparés	4
4	Idéation : 15 candidats conservés	4
5	Trois pistes à approfondir	5
5.1	I01 - Identifier la mémoire manquante avant d'ajouter des paramètres	5
5.2	I02 - Une mémoire lente compacte plutôt qu'une seconde grosse voie audio	5
5.3	I03 - Apprendre l'état initial avec des entrées accessibles	5
6	Pilote de deux semaines proposé	5
7	Ce que cette recherche ne permet pas d'affirmer	6
8	Livrables et limites de cette note	6

1 Résumé

La piste prioritaire est de relier les erreurs à la mémoire réellement nécessaire au dispositif, puis de choisir une représentation et un entraînement adaptés à cette mémoire. Un observer plus gros n'est pas, à lui seul, une hypothèse scientifique suffisante.

Cette revue exploratoire retient 33 références distinctes. Elle articule trois résultats attendus pour une prochaine étude : un diagnostic des erreurs temporelles, une comparaison des modèles sur les mêmes coordonnées et historiques, et un essai borné d'une voie lente compacte. Aucun résultat du job en cours n'a été consulté pour cette recherche et aucun entraînement additionnel n'a été lancé. Les pistes proposées ne modifient pas la campagne gelée.

2 Périmètre et méthode

Question : quelles limites de représentation, d'apprentissage et de mesure empêchent une émulation dry/wet causale de reproduire fidèlement un dispositif analogique, et quelles expériences peu coûteuses permettent de départager ces explications ?

Période recherchée : 2016 au 5 septembre 2026. Inclusion : travaux originaux sur émulation d'effets, filtres différentiables, évaluation et données; travaux adjacents sur états et gradients lorsqu'un mécanisme transférable est explicite. Les travaux de synthèse audio générale sont classés comme preuves indirectes. Prépublications et communications courtes sont admises mais ne sont pas assimilées à des répliques indépendantes.

Sources : arXiv, archive DAFx, PMLR; complément ISMIR, Frontiers et dépôts institutionnels. DBLP sert au contrôle bibliographique. Le CLI paper-search est absent; recherche web ciblée utilisée en remplacement. Il ne s'agit pas d'une interrogation exhaustive des API de trois bases. Les requêtes et exclusions sont conservées dans sources/search_log.md.

Les titres/résumés des 33 notices retenues ont été examinés; des extraits du texte intégral de six travaux centraux ont complété la lecture. Aucun accord inter-évaluateurs, score de citations ou évaluation formelle de risque de biais n'est revendiqué. Les intérêts financiers et financements n'ont pas été extraits systématiquement. On privilégie la pertinence et la qualité du protocole audio plutôt que la notoriété des auteurs.

La déduplication fusionne notamment la prépublication 2502.14405 et son article Frontiers. Wright 2019 et Wright 2020 restent deux publications, mais leurs preuves ne sont pas indépendantes. Les deux publications Comunità 2025 ont des fonctions distinctes : framework et comparaison.

Le corpus satisfait la cible de 30-50 références du skill. La recherche reste une revue exploratoire, pas une revue systématique PRISMA complète : le nombre brut de résultats du moteur web n'est pas un export exhaustif et n'est pas inventé.

Flux de sélection documenté :

- Résultats bruts multi-requêtes : nombre non normalisé.
- Notices primaires retenues et dédoublées : 33.
- Lecture : notices/résumés pour le corpus; extraits de texte intégral pour six références.
- Méta-analyse : aucune; jeux de données, réglages et métriques hétérogènes.

Les DOI présents sont contrôlés séparément par le vérificateur du skill. Un DOI qui résout ne prouve ni la qualité de l'étude ni la reproductibilité d'un score. Pour les références sans DOI renseigné, la notice primaire liée est l'identifiant bibliographique.

Vérification effectuée : quatre DOI résolvent; trois métadonnées CrossRef récupérées. Pour KLANN, le DOI résout mais CrossRef n'a pas fourni de métadonnées au vérificateur; titre, auteurs, année et DOI sont corroborés par la notice institutionnelle Aalto. Les 29 autres références sont reliées à leurs notices primaires; aucun DOI absent n'est inventé.

3 Ce que la littérature permet de conclure

3.1 Architecture et dispositif doivent être distingués

Les résultats publiés ne désignent pas un vainqueur universel. La comparaison multi-effets de Comunità et collaborateurs favorise les SSM et le conditionnement temporel dans son cadre, alors que la comparaison de Simionato et Fasciani décrit des avantages différents selon distorsion, égalisation et compression. Les études ne partagent pas toutes les mêmes données, budgets ou critères : leur divergence n'est pas une contradiction expérimentale démontrée. [1, 14]

Des récurrences modestes sont des baselines crédibles pour l'amplification. Les travaux Wright montrent leur intérêt face à des convolutions plus lourdes; ils ne garantissent pas une généralisation à toutes les mémoires ou tous les réglages. Le résultat historique obtenu sur référence SPICE par Damskägg doit être distingué d'un résultat sur matériel capturé. [3, 4, 8]

Conséquence pour le projet : comparer la capacité utile à budget contrôlé, avec modèles correctement initialisés et mêmes sources, plutôt que déduire la qualité du nombre de paramètres. NablAFx est une base d'implémentation et d'analyse à examiner; son existence ne valide pas automatiquement un adaptateur local. [2]

3.2 La mémoire conservée et le gradient appris ne sont pas la même chose

Dans notre configuration connue, $12000 / 48000 = 0,25$ seconde de TBPTT. Un état peut transporter une information au-delà de cette durée, tandis que le gradient est coupé à la frontière. Cela ne prouve pas un échec; cela expose une hypothèse d'optimisation non testée.

Tallec et Ollivier décrivent le biais de la troncature et une correction pondérée. Aicher et collaborateurs adaptent l'horizon sous des hypothèses de décroissance du gradient. Leurs résultats sur tâches synthétiques ou de langage ne démontrent pas directement un gain sur amplificateurs. [26, 27]

Les études sur compresseurs optiques rendent cette question concrète : les historiques et les combinaisons attaque rapide / release lente restent difficiles dans leur évaluation. S4, S4D, LRU et Mamba fournissent des mécanismes de mémoire, pas un substitut à la vérification de l'horizon effectivement appris. [15, 22, 23, 25, 24]

3.3 Des dynamiques compactes méritent un vrai contrôle

KLANN utilise une représentation non linéaire et des filtres linéaires dans l'espace latent. Les IIR différentiables, filtres all-pole et tone stacks state-space montrent d'autres façons de factoriser la dynamique. Leur intérêt ici est d'offrir des contrôles compacts et interprétables, pas de garantir une supériorité du gray-box. [6, 10, 13, 18]

L'analogie avec l'identification de systèmes est particulièrement utile : les encodeurs d'état initial permettent d'apprendre sur sections indépendantes. Mais la méthode Beintema utilise un historique d'entrées ET de sorties. Une adaptation black-box déployable ne peut pas réclamer le wet réel à l'inférence : encodeur dry-only, préchauffage causal ou observateur autonome doivent être explicitement séparés du contrôle oracle. [28]

DDSP, les ODE neuronales et le contrôle latent d'un phaser alimentent cette factorisation. Les états de circuit accessibles en simulation et les solveurs continus changent toutefois les conditions d'identification. [11, 9, 12, 32]

3.4 Les scores et les oreilles répondent à des questions différentes

La loss perceptuelle de Wright et l'étude de Cassidy séparent précision, réalisme et préférence. Un meilleur ESR ne démontre donc pas une préférence en écoute. Les courbes de résidu sont utiles pour localiser une erreur, mais un fichier presque silencieux peut afficher un ESR élevé pour une très faible erreur absolue. [5, 19]

Pour le failure mining, rapporter conjointement ESR, MAE, niveau cible, résidu spectral, transitoires et position temporelle. Conserver les exemples difficiles sans les transformer en données de sélection de la campagne confirmatoire. EGFxSet enrichit les observations sur matériel réel, mais ses notes isolées ne remplacent pas

des phrases musicales et histoires longues. [20]

La répétabilité matérielle reste une inconnue locale : sans répétitions de captures identiques, on ne peut pas attribuer tout résidu à la modélisation. Une nouvelle capture ne doit jamais être simulée en modifiant le dry tout en conservant artificiellement le même wet.

3.5 Antialiasing et coût sont des axes séparés

Le lissage des activations et l'ADAA récurrent donnent des pistes pour réduire les images repliées; leur effet sur la tonalité doit aussi être mesuré. Adapter une fréquence d'échantillonnage change la dynamique d'un RNN si sa récurrence n'est pas adaptée. [16, 17, 30]

Les grandes dilatations TCN peuvent offrir du contexte à moindre coût. TFILM combine modulation récurrente et convolution; SaShiMi exploite plusieurs échelles pour la génération audio. Ces idées motivent une voie lente basse cadence, mais ne prouvent pas qu'elle préservera les transitoires d'un effet conditionné par son entrée. [7, 29, 21]

WaveNet est à l'origine un modèle de génération autorégressive, distinct de notre régression dry/wet. La prépublication iOS de 2026 concerne surtout pruning et exécution sparse : un gain de déploiement ne vaut pas un nouveau record de fidélité. [31, 33]

4 Idéation : 15 candidats conservés

Les moteurs créatifs utilisés sont la reformulation du problème, l'analogie avec l'identification de systèmes et l'analyse des contradictions mémoire/gradient/coût. Le classement ci-dessous est un jugement de recherche, non une mesure empirique.

ID	Proposition	Mécanisme et test discriminant	Décision
I01	Carte d'horizon mémoire utile	Même suffixe, historique contrôlé; mesurer dépendance du résidu au contexte	Priorité 1
I02	Observer lent basse cadence	États compacts au rythme du contrôle, voie audio rapide inchangée	Priorité 2
I03	État initial dry-only appris	Estimer l'état depuis le passé dry; comparer au préchauffage causal	Priorité 3
I04	Gradient long seulement pour la voie lente	Détacher le fast plus souvent que les états lents	Pilote conditionnel
I05	KLANN minimal comme contrôle	Lift + biquads + projection contre gros observer	À inclure dans I02
I06	Cartographie des constantes de temps	Prédire échecs attaque/release depuis dynamique estimée	À inclure dans I01
I07	Borne de répétabilité du réel	Captures répétées du même probe à réglage fixe	Priorité métrologique
I08	Acquisition informative par désaccord	Capturer surtout où deux modèles figés divergent	Futur, demande nouvelles captures
I09	Loss sensible aux transitoires	Pondération préenregistrée des attaques, contrôle ESR global	Après diagnostic I01
I10	Résidu séparé harmonique/bruit	Modèle déterministe plus estimation du plancher aléatoire	Attendre répétabilité I07
I11	Transfert de fréquence cohérent	Garder les constantes de temps physiques lors du resampling	Hors cycle qualité actuel
I12	Activations antialiasées	Réduire ASR sans confondre baisse ESR et baisse aliasing	Futur protocole séparé
I13	Expert léger par régime	Routage causal selon niveau/historique, sans contrôle futur	Complexité non justifiée encore
I14	Recherche d'architecture plus grosse	Ajouter couches/états sans mécanisme de défaut identifié	Rejetée pour l'instant

I15	Pruning/distillation mobile	Convertir fidélité acquise en coût de déploiement	Hors actuel	scope
-----	-----------------------------	---	----------------	-------

5 Trois pistes à approfondir

5.1 I01 - Identifier la mémoire manquante avant d'ajouter des paramètres

Pitch : les modèles peuvent bien reproduire le timbre moyen tout en échouant sur une attaque dépendante de ce qui précédait. Nous proposons d'estimer l'horizon utile du contexte et du gradient afin de localiser si l'erreur vient de l'état, de son apprentissage ou de la loss.

Trois expériences proposées : 1. Contrôle synthétique à mémoire connue, avec même débit, loss et architecture; varier l'horizon de gradient et mesurer l'erreur après transitions. 2. Sur validation autorisée, comparer le modèle figé avec historique continu et états réinitialisés à différentes distances du passage scoré. Le wet reste celui de la capture originale. 3. Après préenregistrement distinct, comparer deux horizons d'entraînement sur mêmes sources, seeds et budgets. Séparer le gain sur transitoires du gain global.

Invalidateur : aucune sensibilité reproductible à l'historique au-delà de 250 ms, ou aucun gain de l'horizon plus long à budget comparable. Objection forte : on mesure seulement un artefact de reset. Réponse : un contrôle à mémoire connue et une fenêtre de scoring après préchauffage doivent départager cette explication. Originalité non établie; diagnostic d'abord.

5.2 I02 - Une mémoire lente compacte plutôt qu'une seconde grosse voie audio

Pitch : une grande partie de la dynamique pourrait être pilotée par quelques états de contrôle lents, alors que les harmoniques exigent un traitement rapide. Un petit observateur causal multicadence modulerait la voie rapide, avec un contrôle KLANN/IIR de même budget.

Trois expériences proposées : 1. Observer simple constitué d'enveloppes attaque/release apprenables; vérifier son pouvoir explicatif avant toute architecture sélective. 2. Comparer cadence audio et cadence de contrôle réduite avec filtre causal et délai explicite. 3. Comparer IIR latent compact, S4D et modèle actuel sur les régimes identifiés par I01.

Invalidateur : gain absent face aux enveloppes simples, ou erreurs transitoires dues à la cadence réduite. Objection : gray-box et TFiLM existent déjà. Réponse : la contribution doit être la démonstration d'une décomposition valide par régime et son coût, pas le nom de l'architecture.

5.3 I03 - Apprendre l'état initial avec des entrées accessibles

Pitch : des segments courts facilitent l'optimisation mais réinitialisent souvent le système dans un état irréaliste. Un encodeur causal du passé dry fournirait un état initial cohérent sans exiger la sortie du dispositif pendant l'inférence.

Trois expériences proposées : 1. État nul contre préchauffage dry explicite, à contexte réellement identique. 2. Encodeur dry-only contre oracle entrée/sortie strictement marqué non déployable. 3. Vérifier que l'amélioration persiste en streaming complet et après changement de niveau.

Invalidateur : le gain disparaît lorsque le préchauffage de référence est équitable, ou l'encodeur nécessite du wet futur. Objection : états latents non identifiables. Réponse : juger la simulation hors fenêtre et la robustesse, sans prétendre retrouver les variables physiques exactes.

6 Pilote de deux semaines proposé

Aucun pilote n'est lancé dans ce document.

- Jours 1-2 : tableau des conditions d'évaluation, références exécutables, tailles et origines des contextes, délais et supports de scoring. Fixer les critères avant nouveaux scores.

- Jours 3-5 : I01 sur un système synthétique connu puis sur validation autorisée; conserver également les résultats négatifs et les résidus en faible énergie.
- Jours 6-9 : un seul contrôle compact I02, avec deux seeds au minimum pour un signal exploratoire; plafond proposé de 12 GPU-h au total, distinct de la campagne actuelle.
- Jours 10-12 : comparaison du gain par régime et du coût complet, pas uniquement temps d'update.
- Jours 13-14 : décision continuer/abandonner; protocole confirmatoire séparé si justifié.

Critères candidats à préenregistrer : amélioration ESR d'au moins 10 % dans le régime visé, pas de régression globale supérieure à 5 %, stabilité numérique et parité streaming. Ces nombres sont des propositions de pilotage, pas des seuils ajoutés au benchmark en cours.

7 Ce que cette recherche ne permet pas d'affirmer

Aucune supériorité SOTA du projet, aucune causalité entre nos échecs logiciels et une famille d'architectures, aucune garantie qu'une nouvelle loss améliorera l'écoute.

Le matériel du corpus inclut amplis, pédales et compresseurs : généraliser un résultat Ampeg à Rodent/Fuzzy Logic sans confirmation serait injustifié. Un avantage du teacher sur un contrôle ablaté n'est pas une victoire contre le meilleur comparateur ouvert.

Un même nombre d'updates n'est pas un budget de calcul égal. Des coordonnées de scoring identiques n'impliquent pas des historiques identiques. Enfin, les clocks murales, la validation et l'admission GPU doivent être tracées pour rendre un avantage de coût interprétable.

8 Livrables et limites de cette note

- sources/corpus.json : 33 notices, rôle, limites et niveau de lecture.
- sources/search_log.md : requêtes, exclusions et limites de recherche.
- review.bib : références utilisables avec citeproc.
- sources/citations_to_verify.md : DOI renseignés à contrôler automatiquement.
- PDF : rendu de secours avec pdfLaTeX installé; pandoc/xelatex absents et installation système sans mot de passe indisponible. Les citations du PDF restent liées à la bibliographie.
- La vérification automatisée des DOI et le rendu sont séparés de la rédaction scientifique.

Références

- [1] Marco Comunità and Christian J. Steinmetz and Joshua D. Reiss. Differentiable black-box and gray-box modeling of nonlinear audio effects. 2025. [Source primaire](#).
- [2] Marco Comunità and Christian J. Steinmetz and Joshua D. Reiss. NablAFx: A Framework for Differentiable Black-box and Gray-box Modeling of Audio Effects. 2025. [Source primaire](#).
- [3] Alec Wright and Eero-Pekka Damskägg and Vesa Välimäki. Real-Time Black-Box Modelling With Recurrent Neural Networks. 2019. [Source primaire](#).
- [4] Alec Wright and Eero-Pekka Damskägg and Lauri Juvela and Vesa Välimäki. Real-Time Guitar Amplifier Emulation with Deep Learning. 2020. [Source primaire](#).
- [5] Alec Wright and Vesa Välimäki. Perceptual Loss Function for Neural Modelling of Audio Systems. 2020. [Source primaire](#).
- [6] Ville Huhtala and Lauri Juvela and Sebastian J. Schlecht. KLANN: Linearising Long-Term Dynamics in Nonlinear Audio Effects Using Koopman Networks. 2024. [Source primaire](#).
- [7] Christian J. Steinmetz and Joshua D. Reiss. Efficient neural networks for real-time modeling of analog dynamic range compression. 2021. [Source primaire](#).

- [8] Eero-Pekka Damskägg and Lauri Juvela and Etienne Thuillier and Vesa Välimäki. Deep Learning for Tube Amplifier Emulation. 2018. [Source primaire](#).
- [9] Julian D. Parker and Fabián Esqueda and André Bergner. Modelling of nonlinear state-space systems using a deep neural network. 2019. [Source primaire](#).
- [10] Boris Kuznetsov and Julian Parker and Fabian Esqueda. Differentiable IIR Filters for Machine Learning Applications. 2020. [Source primaire](#).
- [11] Jesse Engel and Lamtharn Hantrakul and Chenjie Gu and Adam Roberts. DDSP: Differentiable Digital Signal Processing. 2020. [Source primaire](#).
- [12] Jan Wilczek and Alec Wright and Vesa Välimäki and Emanuël A. P. Habets. Virtual Analog Modeling of Distortion Circuits Using Neural Ordinary Differential Equations. 2022. [Source primaire](#).
- [13] Chin-Yun Yu and Christopher Mitcheltree and Alistair Carson and Stefan Bilbao and Joshua D. Reiss and György Fazekas. Differentiable All-pole Filters for Time-varying Audio Systems. 2024. [Source primaire](#).
- [14] Riccardo Simionato and Stefano Fasciani. Comparative Study of State-based Neural Networks for Virtual Analog Audio Effects Modeling. 2024. [Source primaire](#).
- [15] Riccardo Simionato and Stefano Fasciani. Modeling Time-Variant Responses of Optical Compressors with Selective State Space Models. 2024. [Source primaire](#).
- [16] Ryota Sato and Julius O. Smith III. Aliasing Reduction in Neural Amp Modeling by Smoothing Activations. 2025. [Source primaire](#).
- [17] Otto Mikkonen and Kurt James Werner. Antiderivative Antialiasing for Recurrent Neural Networks. 2025. [Source primaire](#).
- [18] Tantep Sinjanakhom and Eero-Pekka Damskägg and Stylianos Mimilakis and Athanasios Gotsopoulos and Vesa Välimäki. Guitar Tone Stack Modeling with a Neural State-Space Filter. 2024. [Source primaire](#).
- [19] Will Cassidy and Enzo De Sena. Perceptual Evaluation and Genre-specific Training of Deep Neural Network Models of a High-gain Guitar Amplifier. 2023. [Source primaire](#).
- [20] Hegel Emmanuel Pedroza and Gerardo Meza and Iran R. Roman. EGFxSet: Electric Guitar Tones Processed Through Real Effects of Distortion, Modulation, Delay and Reverb. 2022. [Source primaire](#).
- [21] Karan Goel and Albert Gu and Chris Donahue and Christopher Ré. It’s Raw! Audio Generation with State-Space Models. 2022. [Source primaire](#).
- [22] Albert Gu and Karan Goel and Christopher Ré. Efficiently Modeling Long Sequences with Structured State Spaces. 2021. [Source primaire](#).
- [23] Albert Gu and Ankit Gupta and Karan Goel and Christopher Ré. On the Parameterization and Initialization of Diagonal State Space Models. 2022. [Source primaire](#).
- [24] Albert Gu and Tri Dao. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. 2023. [Source primaire](#).
- [25] Antonio Orvieto and Samuel L. Smith and Albert Gu and Anushan Fernando and Caglar Gulcehre and Razvan Pascanu and Soham De. Resurrecting Recurrent Neural Networks for Long Sequences. 2023. [Source primaire](#).
- [26] Corentin Tallec and Yann Ollivier. Unbiasing Truncated Backpropagation Through Time. 2017. [Source primaire](#).
- [27] Christopher Aicher and Nicholas J. Foti and Emily B. Fox. Adaptively Truncating Backpropagation Through Time to Control Gradient Bias. 2020. [Source primaire](#).
- [28] Gerben Beintema and Roland Toth and Maarten Schoukens. Nonlinear state-space identification using deep encoder networks. 2021. [Source primaire](#).
- [29] Sawyer Birnbaum and Volodymyr Kuleshov and Zayd Enam and Pang Wei Koh and Stefano Ermon. Temporal FiLM: Capturing Long-Range Sequence Dependencies with Feature-Wise Modulations. 2019. [Source primaire](#).

- [30] Alistair Carson and Alec Wright and Jatin Chowdhury and Vesa Välimäki and Stefan Bilbao. Sample Rate Independent Recurrent Neural Networks for Audio Effects Processing. 2024. [Source primaire](#).
- [31] Aaron van den Oord and Sander Dieleman and Heiga Zen and Karen Simonyan and Oriol Vinyals and Alex Graves and Nal Kalchbrenner and Andrew Senior and Koray Kavukcuoglu. WaveNet: A Generative Model for Raw Audio. 2016. [Source primaire](#).
- [32] Alistair Carson and Cassia Valentini-Botinhao and Simon King and Stefan Bilbao. Differentiable Grey-box Modelling of Phaser Effects using Frame-based Spectral Processing. 2023. [Source primaire](#).
- [33] Ryota Sato and Eli Silverstein. WaveNet-Style Guitar Amplifier Model Pruning for Real-Time iOS Deployment. 2026. [Source primaire](#).